

SUMÁRIO

1 INTRODUÇÃO.....	13
2 MATERIAL E MÉTODOS	14
2.1 POPULAÇÃO E DESENHO DO ESTUDO.....	14
2.2 COLETA DE DADOS	15
2.3 ANÁLISE DE DADOS	15
4 RESULTADOS E DISCUSSÃO	16
5 CONCLUSÃO	24
REFERÊNCIAS	25
GLOSSÁRIO	26

1 INTRODUÇÃO

Commodities são todas as matérias-primas essenciais que possuem baixo nível de industrialização, do inglês a palavra *Commodity*, significa mercadoria são produtos de origem primária essenciais para o consumo humano e que podem ser estocadas sem que percam a qualidade são produzidas em larga escala e comercializadas no mercado mundial.

Nesse estudo, vamos apresentar uma análise sobre o preço do cobre. O Cobre tem papel fundamental em várias indústrias e atuação importante na exploração mineral tanto em nossos país como no mundo. Atualmente, o cobre é um dos metais não ferrosos mais utilizados no mundo perdendo apenas para o alumínio. As operações de Cobre no Brasil são realizadas pela Bolsa de mercadorias de Nova Iorque (COMEX) e pela Bolsa de Metais de Londres (LME) Os principais compradores do cobre brasileiro são China, Canadá e Estados Unidos.

O Brasil é um grande produtor e exportador de *commodities*. Por isso, o mercado de negociação é tão ativo e oferece muitas oportunidades para os investidores pessoas físicas. As *commodities* são responsáveis por 65% do valor das exportações brasileiras. Apesar do Brasil não ser um grande fornecedor de cobre sua participação gira em torno de 1%, apresenta segundo especialistas grande potencial devido seu grande território e suas jazidas.

Os preços dos futuros de cobre são denominados em dólares norte-americanos por libra (1 contrato CFD (Contract for difference - um contrato por diferença é um contrato entre duas partes, normalmente descrito como "comprador" e "vendedor", estipulando que o comprador pagará ao vendedor a diferença entre o valor atual de um ativo e seu valor no momento do contrato.) inclui 1 libra de cobre, 1 lote contém 30.000 libras de cobre).

Nesse trabalho foi analisado o preço do cobre de 2010 a 2019, apresentaremos suas principais características e em seguida através da aplicação de um modelo estatístico analisaremos se é possível ou não prever os valores futuros dessa série.

2 MATERIAL E MÉTODOS

2.1 POPULAÇÃO E DESENHO DO ESTUDO

A análise de séries temporais é um importante instrumento no entendimento do mercado financeiro e na formulação de planos de ação e estratégias. Os dados passados de uma variável são utilizados na identificação de tendências, sazonalidade e ainda para “prever” observações futuras. Esses modelos estatísticos utilizam dados históricos para dessa forma, poder ter uma ideia, de como a variável se comportará nos próximos períodos.

Uma série temporal pode ser definida como sendo uma sequência de valores ou de leituras ordenadas por um parâmetro temporal (GRANGER; NEWBOLD, 1977).

Pra modelos de previsões em séries temporais são necessários dados do passado para poder prever os valores futuros, modelos de séries temporais são fáceis de utilizar, pois não tem como tentativa achar os fatores que afetam a variável, mas sim tentam descobrir padrões nos dados históricos para poder estimar o futuro. Por isso para aplicar modelos de previsões é fundamental ter informações sobre esses valores no passado.

As séries temporais são bastante utilizadas na economia para observar preços das ações, as taxas de juros, as vendas ou os lucros. Elas podem ser classificadas como discretas quantos as observações tem um intervalo de tempo ou continuas quando essas observações são ininterruptas.

O modelo estatístico usado neste trabalho foi o ARIMA Auto Regressivo Integrado de Médias Móveis que são modelos estatísticos lineares para análise de séries temporais. Os termos integrado correspondem a defasagens da série transformada (isto é, série estacionária obtida por diferenciação) e as médias móveis a defasagens dos erros aleatórios.

2.2 COLETA DE DADOS

Os dados desse estudo foram extraídos do site London Metal Exchange, pelo sítio <https://www.lme.com/>, sendo analisados no Software Rstudio versão 1.2.5033.

A base desse estudo contém 3.296 observações do preço do Cobre observados de janeiro de 2010 a novembro de 2019, em Dólar (USD).

2.3 ANÁLISE DE DADOS

Esse estudo visa trazer uma aplicação de um modelo estatístico para tentar prever os preços futuros do cobre. Primeiramente, foi feita uma análise descritiva dos dados para obtermos estatísticas básicas sobre o banco de dados, em seguida plotado o gráfico para uma visão inicial da série e a sua decomposição a fim de descrever as características básicas da série tais com tendência, sazonalidade e ciclo.

Em seguida, foi feita a auto correlação dos dados, parte muito importante para análise de séries temporais, pois ajuda a definir qual modelo adequado para o estudo, foi usado também o teste Jarque Bera e Shapiro Wilks para testar a normalidade da série e em seguida para verificar se a série é estacionária ou não o teste ADF (Augmented Dickey-Fuller).

Foi aplicado inicialmente o modelo ARIMA que nos deu o resultado do modelo além dos erros médio absoluto e erro médio padrão muito importante a análise dos erros em modelos de séries temporais, pois são esses erros que determinam se será possível prever ou não os valores futuros da série em estudo. Logo em seguida foram feitas as previsões para o período de 30 dias. E por fim, analisado os resíduos.

4 RESULTADOS E DISCUSSÃO

Primeiramente foi feita uma análise descritiva dos dados para um melhor entendimento do nosso banco de dados.

Estatística	US\$
Número obs.	3.296,00
Mínimo	1,94
Máximo	4,63
1. Quartil	2,75
3. Quartil	3,61
Média	3,22
Mediana	3,23
Variância	0,35
Desvio padrão	0,60
Coeficiente de variação (%)	18,49
Coeficiente de assimetria	0,08
Coeficiente de curtose	-0,51
Jarque – Bera (p-valor)	4,271
Shapiro- Wilk (p-valor)	2,303
ADF (p-valor)	0,425

Tabela 1 – análise descritiva e testes

A Tabela 1 apresenta algumas estatísticas descritivas básicas. Observa que o preço médio do cobre durante o período analisado é de US\$ 3,2169, os preços apresentam um coeficiente de variação em torno de 18,5%.

Para verificação da normalidade dos dados foi usado o teste Jarque-Bera e o teste Shapiro -Wilks que ambos indicaram um p - valor menor do que 5%, ou seja, rejeita a normalidade da distribuição da série. Por outro lado, o teste Dickey Fuller apontou um p-valor de 0,425 menor que 5 %, ou seja, rejeitamos a hipótese que a série é estacionária.




Figura 1 – preço do cobre

Na inspeção visual da Figura 1, observa-se um comportamento com tendência, sem sazonalidade e, ao que parece, a série em análise é não estacionária. O que será observado ao longo do estudo a partir de testes específicos. Abaixo temos a decomposição clássica da série que apontou um modelo aditivo sendo o mais adequado, nota-se pela decomposição da série que ela não possui tendência e não é estacionária.

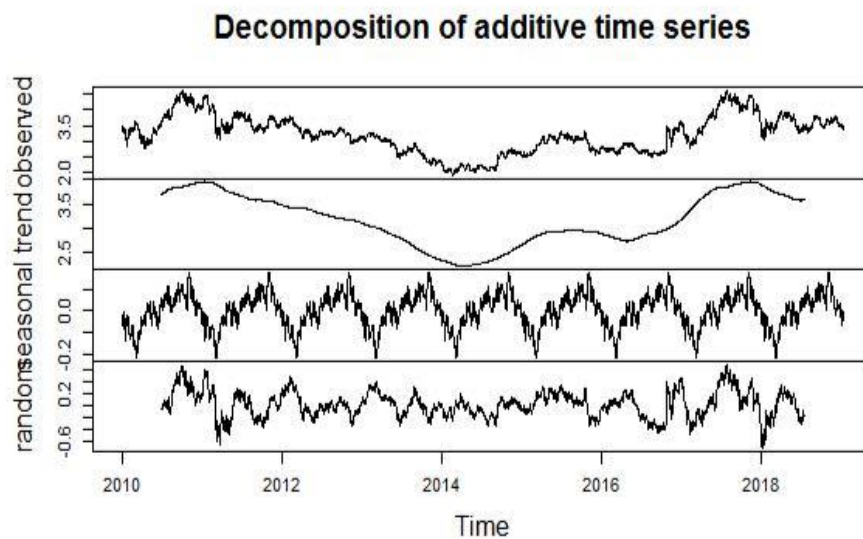


Figura 2 – Decomposição Clássica

Foi feita a análise da função de autocorrelação (FAC) e da função de autocorrelação Parcial (FACP) da série original, que também auxiliou na verificação da estacionariedade e na definição do modelo mais apropriado.

Os gráficos da FAC e da FACP auxiliam na identificação de possíveis modelos para o ajuste dos dados. O comportamento dessas funções indica qual o modelo a ser utilizado. A função de auto correlação é uma medida da correlação entre as observações de uma série temporal que são separadas por k unidades de tempo (y_t e y_{t-k}). A série foi defasada em 2 períodos. Na diferença entre dois períodos os valores obtidos foram os mesmos.




Figura 3 – Defasagem

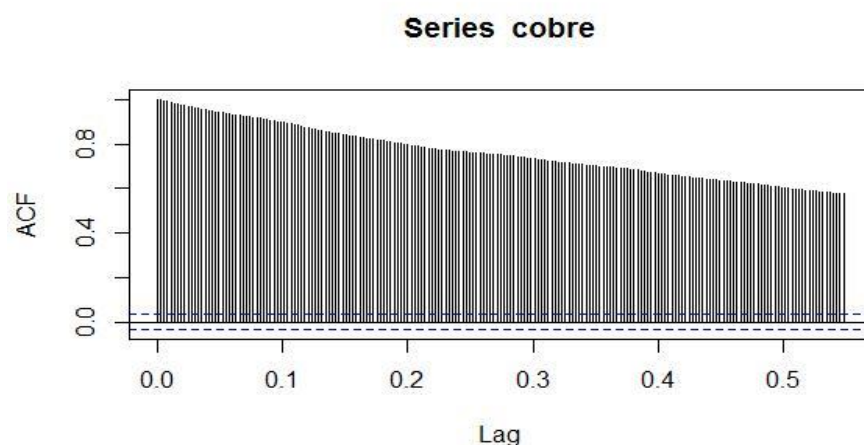


Figura 4 - ACF

Os gráficos de auto correlação (ACF) acima mostra que a série não é estacionária pelo decaimento lento dos *lags*.

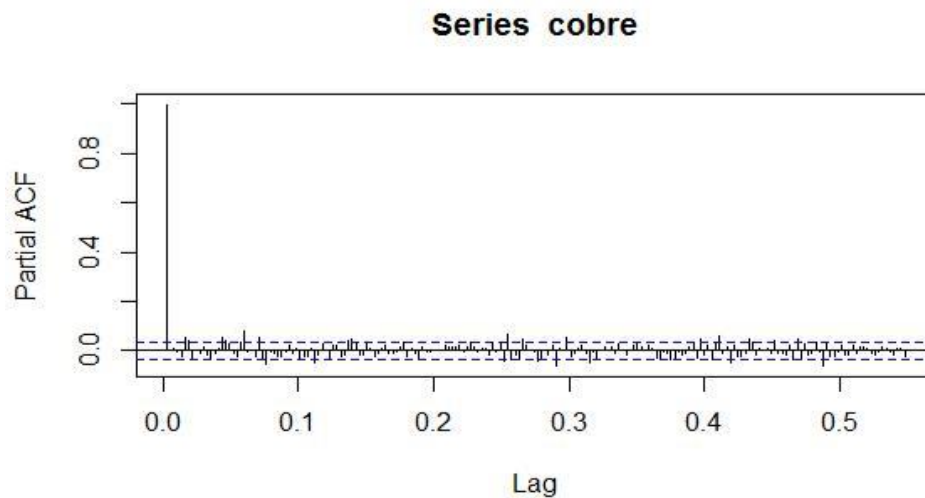


Figura 5 - PACF

Neste gráfico, existe uma correlação significativa no *lag* 1 seguido por correlações que não são significativas. Isso dá indícios de que a parte autoregressiva é não significativa.

APLICAÇÃO DO MODELO.

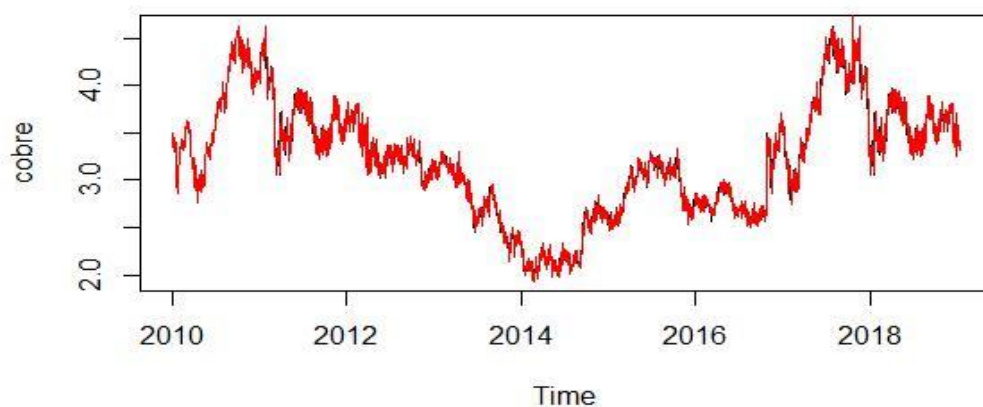


Figura 6 – Função auto.arima

A função `auto.arima` usada nesse trabalho calcula os modelos e escolhe o de menor AIC (ou outro critério que escolher). Aplicamos o modelo ARIMA que resultou em um modelo de ordem (0,1,0) onde $p = 0$ e $q = 0$ o que resulta em uma modelo integrado de ordem 1. Um modelo ARIMA (0,1,0) com uma constante é um passeio aleatório com deriva.

O que foi confirmado com o teste DFA (detrended fluctuation analysis) que apontou um resultado de 1,43 com esse resultado foi confirmado que a série se aproxima de um passeio aleatório.

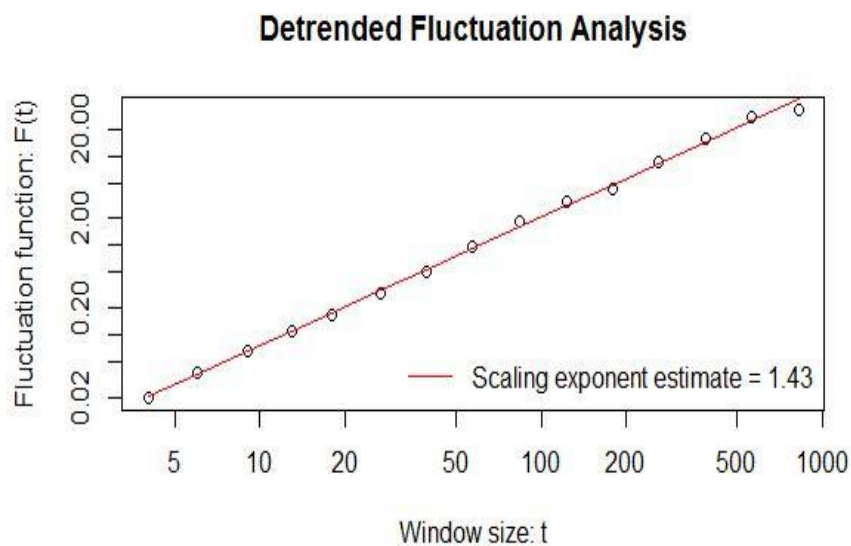


Figura 7 - DFA

ANALISE DE ERROS

```

ARIMA(0,1,0)

sigma^2 estimated as 0.002509: log likelihood=5189.83
AIC=-10377.66 AICc=-10377.66 BIC=-10371.56

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE
Training set -8.523666e-06 0.05007911 0.03499075 -0.01182634 1.078625
0.0600161 ACF1
Training set -0.007002231
> accuracy(modelcobre$fitted, cobre)
      ME      RMSE      MAE      MPE      MAPE      ACF1
Test set -8.523666e-06 0.05007911 0.03499075 -0.01182634 1.078625 -
0.007002231

```

A precisão da previsão é referida à quão perto as previsões chegam dos dados reais. Os indicadores são utilizados para verificar medidas de desempenho do nível de precisão que o modelo de previsão possui. Analisando os erros e a acurácia do modelo proposto pela função `auto.arima` obtemos valores de $ME = -8.5236$ e $MAPE = 1.0786$.

Se ME for pequeno, os dados reais seguem estreitamente as previsões da variável dependente e o modelo de previsão fornece previsões acuradas nesse caso o valor do ME deu alto isso significa que o modelo não conseguiu prever os valores futuros com confiança. Já os Valores pequenos para o $MAPE$ determinam precisão nos dados previstos.

PREVISÕES

Foi aplicado o Modelo de Previsão ARIMA para 30 dias, de ordem (0,1,0) que nos forneceu valores de previsões pouco confiável devido o alto grau de erro.




Figura 8 - Previsão para 30 dias.

Frequency = 365

```
[1] 3.4760 3.4455 3.4275 3.3255 3.1250 3.2905 3.5165 3.4880 3.5575 3.7595 3.7735
[12] 3.6995 3.5700 3.6485 3.6560 3.6320 3.6030 3.6005 3.5085 3.4415 3.5310 3.5555
[23] 3.5690 3.5520 3.4500 3.4695 3.3705 3.4005 3.3465 3.3391
```

ANALISE DOS RESIDUOS

Após a escolha do modelo é necessário realizar a análise de resíduos. Como mostra na figura abaixo. Resíduos são a diferença entre o valor real e o ajustado pelo modelo.




Figura 9 – ACF dos resíduos

Por meio da análise dos resíduos é possível verificar se o modelo escolhido descreve adequadamente o comportamento da série.

Podemos notar pelo gráfico acima que a maior parte dos dados estão concentrado em torno de 0 com variância constante ou seja podemos afirmar que o modelo é adequado aos dados em estudo. Ou seja um modelo integrado de ordem 1 para dados aleatórios.




Figura 10 - Resíduos

5 CONCLUSÃO

Tal como foi apresentado na introdução, o principal objetivo deste trabalho foi aplicar um modelo de previsão para tentar prever possíveis preços da commodity cobre, para alcançar o objetivo foi utilizado o modelo ARIMA um modelo muito usado para se fazer previsões de séries temporais.

Para isso foi feita uma pesquisa descritiva que buscou através do uso de técnicas estatísticas proporcionar um entendimento inicial da série e suas principais características o que nos mostrou ser uma série sem tendência, sem sazonalidade e não estacionária. Através de testes específicos para testar a normalidade dos dados e sua estacionariedade verificamos que os dados não são normais e a série não é estacionária.

Os resultados apontaram um modelo integrado de ordem 1. A série se trata de um passeio aleatório cujos valores futuros não podem ser previstos com precisão devido ao alto valor de erro.

O Objetivo do trabalho foi mostrar técnica estatística de previsão e comprovar que é possível prever valores futuros com base em estudos dos dados passados. Contudo, a base de dados usada nesse estudo não foi possível prever os valores futuros com uma boa precisão por se tratar de um passeio aleatório.